

Big Data - Analisis Exploratorio de Datos

Utilizando la herramienta [Orange Data Mining](#), importe el archivo de datos hogares.csv y elabore un informe con las respuestas a las preguntas indicadas en esta guía.

Hogares.csv contiene datos ficticios de 100 hogares encuestados.

Condiciones de entrega

- Entrega Grupal: Deben entregarlo por Github con el nombre del grupo -
- Plazo máximo: hasta la siguiente clase.

Diccionario de Datos

HogarID: Identificador único del hogar, entero que va de 1 a 100.

IngresoMensual: Ingresos totales del hogar por mes, en pesos argentinos (ARS). Representa la suma de todos los ingresos de los miembros del hogar.

GastoMensual: Gastos totales del hogar por mes, en pesos argentinos (ARS). Incluye gastos fijos (como alquiler o hipoteca, servicios, etc.) y gastos variables (como alimentación, transporte, ocio).

NumPersonas: Número de personas que conforman el hogar. Valor entero que indica la cantidad de individuos viviendo en el hogar.

TipoVivienda: Tipo de estructura habitacional donde reside el hogar. Puede ser "Casa" o "Departamento", reflejando las diferentes modalidades de vivienda.

ZonaVivienda: Zona geográfica donde se ubica el hogar. Las categorías incluyen "Urbana", "Suburbana" y "Rural", indicando el contexto geográfico y posiblemente socioeconómico de la vivienda.


EdadPromedioHogar: Edad promedio de los miembros del hogar, en años. Esta variable es un promedio de las edades de todos los individuos que conforman el hogar.

Guía de Preguntas

1. Análisis de Tendencia Central y Dispersión (Feature Statistics and Distributions):

Calcule las medidas de tendencia central (media, mediana) y dispersión (varianza, desviación estándar) para las variables IngresoMensual, GastoMensual, y EdadPromedioHogar. ¿Los valores encontrados son consistentes con lo que esperarías en un contexto económico real?

Column	Distribution	Mean	Mode	Median
IngresoMensual		91719.9	40607.4	91055.7
GastoMensual		62151.3	20623.9	62352.3
EdadPromedioHogar		40.192	36	38



Ingreso Mensual

Media: 91.719,9

Mediana: 91.055,7

Desviación estándar: 32.559,8

Varianza: 1.060.140.576.04


Gasto Mensual


Media: 62.151,3

Mediana: 62.352,3

Desviación estándar: 24.979,4

Varianza: 623.970.424,36





Edad promedio hogar

Media: 40,192

Mediana: 38


Desviación estándar: 16,5556

Varianza: 274,09

En general, los valores de ingresos y gastos parecen normales dentro de este conjunto de datos. En la edad promedio también los valores centrales son razonables, aunque hay algunos casos muy extremos que hacen que los datos estén más dispersos de lo esperado.

2. Verificación de Máximos y Mínimos (Feature Statistics):

Identifique los valores máximos y mínimos para IngresoMensual, GastoMensual, y EdadPromedioHogar. ¿Estos valores son realistas? Discuta cualquier valor que parezca inusual o fuera de lo esperado.



Ingreso Mensual

- Min: 40.607,4
- Max: 148.558

Gasto Mensual

- Min: 20.623,9
- Max: 127.691


Edad Promedio Hogar

- Min: -5
- Max: 120


Los valores de ingreso y gasto parecen razonables dentro del conjunto de datos. En cambio, en Edad Promedio Hogar aparecen valores de -5 y 120 años, que no son realistas como edad promedio de un hogar. Esos valores podrían deberse a errores de carga o datos atípicos.

3. Relación entre Variables (Scatter Plot):

Explore la relación entre el EdadPromedioHogar y otras variables numéricas como IngresoMensual y GastoMensual. ¿Hay alguna tendencia visible que indique cómo la edad promedio del hogar afecta los ingresos y gastos?




No se observa una relación clara entre la edad promedio del hogar y los ingresos o gastos. En ambos gráficos los puntos están bastante dispersos y las correlaciones son muy cercanas a 0 ($-0,01$ y $-0,05$), por lo que la edad promedio del hogar no parece influir de manera importante en los ingresos ni en los gastos.



4. Análisis de Outliers (Box Plot):


Utilizando técnicas gráficas, identificar datos atípicos en las variables numéricas. Describa por qué estos puntos podrían considerarse atípicos y qué factores podrían explicar estos valores.



En los gráficos se observa que Edad Promedio Hogar es la variable que presenta los valores más atípicos, especialmente -5 y 120 años, ya que están muy alejados de la mayoría de los datos. Estos valores podrían deberse a errores de carga o datos incorrectos. En cambio, en Ingreso Mensual y Gasto Mensual no se observan valores atípicos tan marcados, ya que los valores están más distribuidos dentro de rangos esperables.


5. Comparación entre Grupos (Box Plot):

Analice cómo varía la EdadPromedioHogar entre diferentes tipos de vivienda (Casa, Departamento) y zonas de vivienda (Urbana, Suburbana, Rural). ¿Existen diferencias significativas que puedan sugerir patrones demográficos?




Se observan diferencias en la edad promedio según el tipo y la zona de vivienda. Los hogares en departamentos tienen una edad promedio mayor que los de casas.

Por zona, los hogares rurales tienen la edad promedio más alta, los suburbanos quedan en el medio y los urbanos tienen la más baja. Esto podría indicar algunos patrones demográficos entre las distintas zonas y tipos de vivienda.



6. Correlaciones (Correlations):

Investigue la correlación entre las variables numéricas. ¿Qué relaciones se pueden identificar como relevantes y cómo se interpretan?



La relación más relevante es entre Ingreso Mensual y Gasto Mensual, con una correlación de 0,895, lo que indica una relación positiva fuerte: los hogares con mayores ingresos tienden a tener mayores gastos. En el resto de las variables las correlaciones son cercanas a 0, por lo que no se observa una relación importante.